

一句话总结

动态 Agent 工作流的错误停止，并不只是“没找全东西”，而是把局部 source-route 条件下产生的 no-new / agreement / self-completion 误当成了全局完成证据；我们将这一问题形式化为 completion certificate mismatch，并用 source-route evidence-condition geometry 判断当前停止证据是否有资格支撑 completion claim。

一段话总结

这篇论文研究 dynamic agent workflows 中的 false completion / false certification 问题。很多动态工作流需要在未知剩余工作量的情况下决定是否停止，例如代码审计、文档审查、策略检查、deep research 或 claim verification。现有工作流常用 no-new findings、agent agreement、stable summary 或 self-reported completion 作为停止信号，但这些信号其实都依赖于它们产生时的证据条件：Agent 到底检查了哪些 source，又通过哪些 route 检查。

我们认为，错误停止的本质是 certificate mismatch：stop evidence 的产生条件是局部的，但 stop claim 声称的是全局完成。为此，我们定义 source-route stratum $s=(x,r)$ ，用 runtime exposure distribution $p_{\text{exp}}(t,s)$ 表示完成证据产生的条件，并提出 evidence-condition controller：当证据条件太局部时拒绝 SAFE；当证据条件较广但仍有 residual evidence 时输出 CONTINUE；只有 broad exposure 且 repair/audit 不再产生残余证据时才输出 SAFE。

当前论文的主贡献是 evidence-condition geometry 和 safe-stopping controller，而不是声称 residual-potential 是最优搜索算法。

1. 背景与动机

现在很多 Agent 系统不再只是回答一个单步问题，而是执行动态工作流：代码审计、文档审查、策略检查、deep research、claim verification、root-cause analysis 等。这类任务有一个共同点：系统运行时通常不知道剩余工作量到底有多大，也不知道还有多少相关证据没有被发现。

因此，工作流必须依赖一些运行时停止信号，例如最近没有新发现、多个 Agent 输出一致、summary 稳定、Agent 自己说完成了，或者分配的子任务看似都关闭了。

但这些信号不是无条件成立的证据。它们只是在工作流实际检查过的 source-route 条件下成立。

例如，在代码审计里，如果 Agent 反复检查某几个文件的 timeout 行为，并且最后没有新发现，这只能说明这些文件在 timeout route 下可能局部耗尽；它并不能说明同一批文件在 TLS、retry、exception、cleanup route 下也都被充分审计过。

local stop evidence is promoted into a global completion certificate.

也就是说，系统把局部条件下成立的停止证据，错误地提升成了全局完成证据。

2. 核心机制：Completion Certificate Mismatch

我们把这个失败称为 certificate mismatch。它包含两个对象。

2.1 Stop Evidence

工作流产生的停止证据，例如：

no-new, agreement, self-completion

这些证据来自具体的 source-route 条件。

2.2 Completion Claim

工作流最后声称：

C_t : task T is complete over the intended workload scope.

问题在于：

$$\text{support}(\text{stop evidence}) \ll \text{scope}(\text{completion claim})$$

也就是说，证据的支撑范围是局部的，但声明的完成范围是全局的。这比“Agent 没找全东西”更深一层。不是简单地说 Agent 漏了 item，而是说：

当前证据本身没有资格支持当前完成声明。

3. 几何对象：Source-Route Evidence-Condition Geometry

为了描述 stop evidence 是在什么条件下产生的，我们定义 source-route stratum:

$$s = (x, r)$$

其中，x 是 source，例如文件、模块、文档、source family；r 是 route，例如 timeout audit、TLS audit、exception audit、policy-exception audit、cleanup audit。

整个 intended evidence-condition space 是：

$$\Omega = S \times R$$

工作流在运行时会产生 evidence events:

$$e_t = (a_t, x_t, r_t, u_t, o_t, c_t)$$

其中每个 evidence event 都发生在某个 source-route 条件下。我们用 $v_t(s)$ 表示到时间 t 为止，工作流在 stratum s 上的 exposure 次数。然后定义 exposure distribution:

$$p_{\text{exp}}(t, s) = \frac{v_t(s)}{\sum_{s' \in \Omega} v_t(s')}$$

这个分布就是我们的 evidence-condition geometry。它不是在问“Agent 找到了多少 item”，而是在问：

completion evidence 是在哪里、通过什么 route 产生的？

当 p_{exp} 集中在少数 strata 上时，说明 stop evidence 是局部条件下产生的。此时 no-new / agreement 可能说明局部耗尽，但不能说明全局完成。

4. 核心命题：Local No-New Evidence Is Not Global Completion

论文里目前最关键的理论表述可以写成：

如果所有支持 stop claim 的证据都只产生在 $U \subset \Omega$ 中，并且 no-new signal 也只是在 U 内观察到的，那么这个 no-new evidence 只能支持 U 内的 local exhaustion，不能支持整个 Ω 上的 global completion。

直觉很简单：如果 $\Omega \setminus U$ 根本没有被检查过，那么工作流无法区分下面两个世界：

1. U 已经耗尽, ΩU 也没有残余证据;
2. U 已经耗尽, 但 ΩU 仍然有大量残余证据。

在当前 evidence log 下, 这两个世界是不可区分的。所以 local no-new 不能推出 global completion。

这个命题虽然简单, 但它是论文机制的核心: 它把问题从“召回率不够”提升成了“证书支撑条件不充分”。

5. 方法: Evidence-Condition Controller

基于上面的几何对象, 我们提出 evidence-condition controller。它不是一个普通搜索增强器, 而是一个 stop decision controller。

当 workflow 提出 stop claim 时, controller 做以下事情: 读取 runtime evidence log; 计算 source-route exposure distribution; 判断 evidence condition 是否过于局部; 如果太局部, 不允许 SAFE; 对 weak but plausible strata 做 repair / audit; 如果 repair 找到 residual evidence, 则 CONTINUE; 如果 broad exposure 且没有 residual evidence, 则 SAFE; 如果预算耗尽但证据仍不足, 则 ABSTAIN。

controller 的核心思想是:

broad exposure $\neq$ completion proof

更准确地说:

broad exposure = completion eligibility

SAFE = broad exposure + no residual evidence after repair/audit

这点很重要。我们不是说覆盖广了就一定完成, 而是说: 只有证据条件足够广, 当前 stop evidence 才有资格被考虑为 completion certificate。

6. Repair Instance: Residual-Potential

实验中使用了一个机制对齐的 repair rule:

$\text{priority}(s) = \text{under_exposure}(s) \times \text{runtime_potential}(s)$

其中, $\text{under_exposure}(s)$ 表示当前 completion certificate 中这个 stratum 的支撑是否薄弱; $\text{runtime_potential}(s)$ 表示基于运行时可见信息估计这个 stratum 是否仍可能产出有效证据。

这里不能使用 oracle labels、oracle totals、missing mass、undiscovered true items、post-hoc recall 等信息。

residual-potential 不是论文的核心理论贡献, 也不是被证明最优的搜索算法。

它只是 evidence-condition repair 的一个实例。论文主贡献是 evidence-condition geometry 和 controller, 而不是 residual-potential 本身。

7. 当前论文主线

这篇论文现在的主线可以概括为:

工程现象 $\rightarrow$ 机制解释 $\rightarrow$ 几何对象 $\rightarrow$ 控制原则 $\rightarrow$ 实验验证

7.1 工程现象

多 Agent / dynamic workflow 明明出现 no-new、agreement、self-completion, 却仍然可能 false completion。

7.2 机制解释

停止信号是局部条件下产生的, 但完成声明是全局的。本质是 completion certificate mismatch。

7.3 几何对象

source-route exposure distribution:

$$p_{\text{exp}}(t, s)$$

它描述 stop evidence 是在什么条件下产生的。

7.4 控制原则

当前不是一个强理论临界量，而是 runtime operational diagnostics:

$$\text{support}(t), \quad G_{\text{exp}}(t)$$

它们用来判断 evidence condition 是 localized 还是 broad。

7.5 方法导出

- localized $\rightarrow$ not SAFE;
- broad but productive $\rightarrow$ CONTINUE;
- broad and stable $\rightarrow$ SAFE;
- weak plausible strata $\rightarrow$ repair / audit。

8. 实验验证的角色（简要）

这一版说明里不展开具体实验细节，只说明实验承担的作用：

3. 验证 homogeneous route reuse 是否会产生 localized evidence condition;
4. 验证 localized stop evidence 是否会导致 false certification risk;
5. 验证 broader source-route exposure 是否提升 completion eligibility;
6. 验证 broad exposure 不是 SAFE 的充分条件;
7. 验证 residual-potential 只是一个有用但有限的 repair instance。

也就是说，实验不是为了证明我们提出了最强 item discovery policy，而是为了验证这条机制链：

$$\text{localized evidence condition} \Rightarrow \text{unsafe completion claim} \Rightarrow \text{need evidence-condition control}$$

9. 当前不足与下一步

9.1 还没有强 order parameter

support / Gini 是有效诊断，但还不是 universal threshold。论文不能写成“发现了 phase transition”。

9.2 source-route space 是任务设计的

它很合理，但不同任务里 sources 和 routes 需要定义。这会影响理论普适性。

9.3 外部任务是 pattern-defined oracle

真实 repo 上的 pattern-defined oracle 比 toy task 强，但还不是人工标注 benchmark。

9.4 实验仍偏 bounded audit

虽然问题定义更广，但 claim verification / root-cause / deep research completeness 还只是 future validation。

9.5 residual-potential 不是强算法贡献

它是机制对齐的 repair instance，不是最优方法。

10. 当前论文最适合的定位

A mechanism and controller paper for safe completion decisions in dynamic agent workflows.

不是：

A new optimal search algorithm.

更准确地说：

本文提出 *evidence-condition geometry*，用于判断动态 Agent workflow 中的 *stop evidence* 是否有资格支撑 *completion claim*，并提出 *evidence-condition controller* 以避免 *localized evidence* 被错误接受为 *global completion certificate*。

11. 通俗解释

可以把动态 Agent workflow 想象成一群人在检查一栋楼。

他们检查了几间教室，发现没什么新问题，于是说：“我们检查完了。”

但问题是，他们只检查了“教室里的电路”，没有检查“实验室的消防”“楼梯间的监控”“办公室的门禁”。所以他们的 *no-new* 只说明：在已经检查过的教室电路这一小块区域里，暂时没有新问题。它不能说明：整栋楼所有风险都检查完了。

我们的 *source-route geometry* 就是在记录：他们到底检查了哪些区域，以及用什么检查路线检查的。

不是“没有新发现”就能停，而是要先问：这个“没有新发现”是在多大的证据条件下产生的？