

ICLR2027（待投稿） 一句话总结

一句话总结

低秩模型合并存在由维度比 r/d 控制的相变——当秩足够小时子空间天然正交（安全），秩足够大时必然重叠（危险），我们不仅从 Grassmann 流形几何证明了这一相变的双临界点，还据此设计了一个在危险区仍能安全合并的方法。

一段话总结

本文发现并理论证明了 **Rank-Phase Transition（秩相变）**：在 d 维表示空间中，两个 r 维 LoRA 任务子空间的期望夹角满足 $E[\theta] \geq \arccos(r/d)$ ，由此导出两个临界阈值——**屈服强度** $r^*/d \geq 0.03$ （合并开始退化）和**断裂强度** $r^*/d = 0.5$ （子空间必然重叠）。这一相变解释了为什么现有方法（TIES、DARE）在标准秩 $r=16$ 时有效，但在高秩 $r=256$ 时崩溃。基于投影算子对易子导出的几何序参量 $\sin^2(2\theta)/4$ ，我们提出 **ManifoldMerge**：在正交区自动退化为均匀合并（无害），在重叠区通过兼容性引导的选择性投影保留建设性方向、消除破坏性干扰。在 8 域 SuperNI 上，Per-Task Selective Projection 达到 51.8%（ME%=120.7%），超越 11 个基线；该理论还实现了零超参数秩选择（预言 $r \approx 0.03d$ ）和方法崩溃点预测（TIES 在 $r \geq 256$ 时灾难性失效）。

非常详细的解释

1. 背景与动机

模型合并（Model Merging） 是持续学习中的一个重要范式：为不同任务独立训练 LoRA 适配器，然后将它们合并成一个模型，无需联合训练也无需任务身份。现有方法主要分为两类：

- **盲合并**：Task Arithmetic（简单平均）、TIES（修剪+符号选举）、DARE（随机丢弃）
- **自适应合并**：AdaMerging（用测试数据优化层系数）、OPCM/NUFILT（增量投影）

但这些方法有一个共同盲区：**它们把合并安全性当作与秩无关的常数**。实践中大家发现 $r=16$ 时合并很安全， $r=256$ 时经常崩溃，却没有人系统地问：**崩溃是从哪里开始的？能不能预言？**

2. 核心发现：Rank-Phase Transition

本文的核心发现是：**合并安全性不是连续变化的，而是随 r/d 比值发生相变**。

在 d 维空间 $\mathbb{R}^d$ 中，两个 r 维子空间 U_1, U_2 的相对几何由 **principal angles** $\theta_1 \leq \dots \leq \theta_r$ 刻画。我们在 Grassmann 流形 $\text{Gr}(r, d)$ 上证明了三个理论结果：

定理 1：投影算子对易子（几何序参量）

设 $P_i=U_iU_i^H$ 为投影算子，则对易子的 Frobenius 范数满足精确恒等式：

$$\| [P_1,P_2] \|_F^2=2\sum_{k=1}^r\sin^2(2\theta_k)$$

定义 **角向非对易性** $U(\theta)=4\sin^2(2\theta)$ ，它在 $\theta=0$ 和 $\theta=\pi/2$ 时为零，在 $\theta=\pi/4$ 时达到最大值 1/4。

物理意义：完全正交（ $\theta=\pi/2$ ）和完全对齐（ $\theta=0$ ）的子空间都不会产生干扰，**最危险的是部分重叠**（ $\theta\approx\pi/4$ ）。这是一个反直觉的非单调结构。

定理 2：秩相变的双临界点

确定性边界（断裂强度）：对任意两个 r 维子空间，维度公式给出 $\dim(U_1\cap U_2)\geq 2r-d$ 当 $2r>d$ 时交集必然非空，至少有一个 principal angle 为零： $d_{theory}=2r$

概率下界（屈服强度）：对 Haar-随机子空间，trace identity 给出 $\sum_{k=1}^rE[\cos^2\theta_k]=dr$ 由 Jensen 不等式（ $\arccos(\cdot)$ 在 $[0,1/2]$ 上凸）： $E[\theta^-]\geq\arccos(dr)=2\pi-dr-O((dr)^{3/2})$

令 $E[\theta^-]=80^\circ$ （经验观测到的合并退化阈值），解得： $d_{practical}\geq(18\pi)^2\approx0.0305$

三安全区：

区域	r/d 范围	期望夹角	合并策略
Safe	≤ 0.012	$\geq 77^\circ$	盲合并安全
Transition	$0.012\sim0.054$	$73^\circ\sim77^\circ$	建议监控兼容性
Danger	≥ 0.054	$\leq 73^\circ$	必须兼容性引导

关键洞察： $r_{theory}/d=0.5$ 和 $r_{practical}/d\approx0.03$ 之间有 **10 倍差距**——就像材料的屈服强度远低于断裂强度一样，"合并开始退化"远早于"子空间必然重叠"。

定理 3（约束相变）：非 Haar-随机分布

实际 LoRA 子空间不是 Haar-随机的（任务优化使它们更对齐）。我们用 Radon-Nikodym 框架证明：**只要实际分布与 Haar 测度的 RN 导数有界，相变就仍然存在**，只是临界点可能偏移。这回应了核心质疑。

局部相变：模块维度异质性

LLaMA-3.1-8B 中不同层有不同输出维度：

- k_proj/v_proj : $d_{out}=1024$
- q_proj/o_proj : $d_{out}=4096$
- $gate_proj$: $d_{out}=14336$

当全局 $r/d=16/4096=0.39\%$ 时， k_proj/v_proj 的局部比是 $16/1024=1.56\%$ ，已经进入 transition zone。这解释了为什么 $r=16$ 的 orthogonal ratio (46.6%) 反而低于 $r=32$ (50.6%)——**小维度模块先发生局部相变**。

3. 方法：ManifoldMerge

ManifoldMerge 不是独立的工程贡献，而是验证 Rank-Phase Transition 的平台。其核心是秩感知的优雅退化：

3.1 兼容性评分

从对易子到合并干扰的推导：投影差 $\Pi_i - \Pi_j$ 作用于任务向量 ΔW_j 的二次型展开后，得到兼容性分数： $S(i,j)=L1 \sum_{l=1}^L [\alpha \sum_{k=1}^r \cos(\theta_{kl}) \rho(\sigma_{i,kl}, \sigma_{j,kl}) - 4\beta \sum_{k=1}^r \sin^2(2\theta_{kl}) \sigma_{i,kl} \sigma_{j,kl}]$

- 建设性项： $\cos(\theta_k) \approx 1$ 且幅度匹配 $\rho \approx 1 \rightarrow$ 正迁移
- 破坏性项： $\sin^2(2\theta_k)/4$ 在 $\theta=\pi/4$ 最大 $\rightarrow$ 精确捕获干扰区

3.2 选择性投影

对每个 principal direction：

- 建设性方向：直接加权合并
- 破坏性方向：投影到已合并子空间的正交补（消除干扰）

3.3 Per-Task 合并顺序

消除"先来先服务"效应：对每个目标任务 t ，合并顺序为 $Order(t)=[t]+\text{argsort}_j(\boxtimes=t(S(t,j),\text{descending}))$ 目标任务最先合并（信息不被稀释），最兼容的任务次之。

3.4 深度感知分层合并

反直觉发现：深层应该均匀合并，浅层应该选择性投影。因为深层重叠编码了跨任务语义共享，选择性投影会过度消除有益共享方向。

4. 实验验证

4.1 主实验（SuperNLI, 8域, r=256r=256）

方法	AP	ME%
STU（单任务上界）	42.9	100
TIES	40.41	94.2
DARE+TIES	43.4	101.2
OPCM	39.62	92.4
MM-PT-SP (Ours)	51.8	120.7

MM-PT-SP 不仅超越所有基线，还**超过单任务上界**——说明兼容性引导的合并通过跨任务知识迁移实现了正迁移。

4.2 秩相变验证（10 ranks）

系统扫描 $r=16,24,32,48,64,96,128,192,256,512$:

r	r/d	AvgAngle	Orth(80°)	Zone
16	0.39%	75.9°	46.60%	Safe
64	1.56%	77.1°	51.50%	Transition
128	3.12%	75.5°	47.00%	Transition
256	6.25%	72.3°	37.90%	Danger
512	12.50%	66.0°	15.80%	Danger

- 平均夹角跟踪理论下界，负偏差有界 ($\leq 10.5^\circ$)
- Orthogonal ratio 指数衰减: $p_{\perp}=0.546\cdot e^{-7.10\cdot r/d}$, $R^2=0.87$

4.3 多种子稳健性 (5 seeds)

r	Mean Orth%	Std
16	46.95%	0.36%
256	37.50%	0.20%

标准差 <1%，证明相变是统计稳健的。

4.4 跨模型/规模/模态验证

- 跨模型: Llama-3.1-8B ↔ Qwen2.5-7B, 相同 r/d 下相同相变曲线
- 跨规模: 1B/3B/8B, r/d 归一化后一致
- 跨模态: CLIP ViT-B/16 (VTAB-1k), $d=768$, TIES 在 $r/d=16.7\%$ 崩溃
- **GLUE**: TIES 在 $r=64$ ($r/d=1.56\%$) 灾难性崩溃 (CoLA=0, MRPC=0)

5. 应用：理论预言力

5.1 零超参数秩选择

理论预言最优秩 $r^*\approx 0.03d$ 。对 Llama-3.1-8B ($d=4096$)，预言 $r^*\approx 123$ ，实验峰值在 $r=128$ (AP=42.7)。

5.2 方法崩溃预测

Orthogonal ratio 的指数衰减预言 TIES 在 $p_{\perp}\approx 38\%$ 时崩溃，对应 $r\geq 256$ ——实验精确验证。

5.3 $r=512$ 的自动退化

理论预言在 danger zone constructive mask 会全部消失，selective projection 自动退化为 uniform averaging。实验确认：selective=lazy 给出完全相同结果 (AP=40.33)。

6. 非线性验证

验证线性近似 $\delta h \approx \Delta W \cdot h_0$ 的残差： $\epsilon_{nl} \approx 0.25\%$ 线性近似捕获了 99.75% 的表征修改，理论在非线性网络中仍然成立。

通俗解释

想象你有一个大仓库（ $d=4096$ 维空间），每个任务需要在仓库里租一小块地方放自己的东西（ r 维子空间）。

问题：当很多任务同时在仓库里放东西时，它们的地盘会重叠吗？重叠了就会互相干扰（合并后性能下降）。

传统做法：大家闭着眼睛随便放（盲合并），或者请个顾问来看一眼再调整（需要测试数据的自适应方法）。

我们的发现：其实不用那么复杂——**重叠不重叠，完全取决于你的"地盘大小"和"仓库大小"的比例。**

- 如果你只占仓库的 0.4%（ $r=16$ ），那基本碰不到别人——大家都正交，闭着眼睛合并也没事。
- 如果你占到 6%（ $r=256$ ），地盘开始严重重叠，闭着眼睛合并就会灾难性崩溃。
- 如果你占到 50%（ $r=2048$ ），那必然重叠，神仙也救不了。

更神奇的发现：最危险的不是"完全重叠"（大家都放同一个地方，反而可以互相加强），也不是"完全不重叠"（各放各的，互不干扰），而是**"半重叠"**——你的东西有一半和我的东西挤在一起，但方向相反，结果互相抵消。

我们的方法（ManifoldMerge）：就像开会安排座位——

- 先判断哪两个人合得来（兼容性评分）
- 合得来的人坐一起（建设性方向直接合并）
- 合不来但不得不一起的，让他们背靠背坐（破坏性方向正交投影，互不干扰）
- 最重要的是：**每个人当主角时都坐C位**（Per-Task 顺序），不会被别人的安排稀释

实际效果：在 8 个不同任务的合并中，我们的方法比现有最好方法高出 11 个百分点，甚至超过了每个任务单独训练的上限——说明合理安排座位真的能让大家互相学习。

最实用的功能：你再也不用试 10 个不同的秩来找最优配置了——我们的公式直接告诉你：**最优秩 $\approx 0.03 \times \text{模型维度}$** ，一步到位。